

目录	1
----	---

## 目录

1 Template	2
2 Q learning 算法	3
3 Sarsa 算法	4
4 DQN 算法	5
5 PER_DQN 算法	6
6 Policy Gradient 算法	7
7 Advantage Actor Critic 算法	8
8 PPO-Clip 算法	9
9 DDPG 算法	10
10 SoftQ 算法	11
11 SAC-S 算法	12
12 SAC 算法	13

# 1 Template

算法 <sup>①</sup>
1: Test

<sup>①</sup>this is footnote

## 2 Q learning 算法

---

### Q-learning 算法<sup>①</sup>

---

- 1: 初始化 Q 表  $Q(s, a)$  为任意值, 但其中  $Q(s_{terminal}, \cdot) = 0$ , 即终止状态对应的 Q 值为 0
  - 2: **for** 回合数 =  $1, M$  **do**
  - 3:   重置环境, 获得初始状态  $s_1$
  - 4:   **for** 时步 =  $1, T$  **do**
  - 5:     根据  $\varepsilon - greedy$  策略采样动作  $a_t$
  - 6:     环境根据  $a_t$  反馈奖励  $r_t$  和下一个状态  $s_{t+1}$
  - 7:     更新策略:
  - 8:      $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_t + \gamma \max_a Q(s_{t+1}, a) - Q(s_t, a_t)]$
  - 9:     更新状态  $s_{t+1} \leftarrow s_t$
  - 10:   **end for**
  - 11: **end for**
- 

---

<sup>①</sup>Reinforcement Learning: An Introduction

### 3 Sarsa 算法

---

**Sarsa 算法<sup>①</sup>**

---

- 1: 初始化 Q 表  $Q(s, a)$  为任意值, 但其中  $Q(s_{terminal}, \cdot) = 0$ , 即终止状态对应的 Q 值为 0
  - 2: **for** 回合数  $= 1, M$  **do**
  - 3:   重置环境, 获得初始状态  $s_1$
  - 4:   根据  $\varepsilon - greedy$  策略采样初始动作  $a_1$
  - 5:   **for** 时步  $= 1, t$  **do**
  - 6:     环境根据  $a_t$  反馈奖励  $r_t$  和下一个状态  $s_{t+1}$
  - 7:     根据  $\varepsilon - greedy$  策略  $s_{t+1}$  和采样动作  $a_{t+1}$
  - 8:     **更新策略:**
  - 9:      $Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha[r_t + \gamma Q(s_{t+1}, a_{t+1}) - Q(s_t, a_t)]$
  - 10:    更新状态  $s_{t+1} \leftarrow s_t$
  - 11:    更新动作  $a_{t+1} \leftarrow a_t$
  - 12:   **end for**
  - 13: **end for**
- 

---

<sup>①</sup>Reinforcement Learning: An Introduction

## 4 DQN 算法

---

### DQN 算法<sup>①</sup>

---

```

1: 初始化策略网络参数  $\theta$ 
2: 复制参数到目标网络  $\hat{Q} \leftarrow Q$ 
3: 初始化经验回放  $D$ 
4: for 回合数 = 1,  $M$  do
5:   重置环境, 获得初始状态  $s_t$ 
6:   for 时步 = 1,  $t$  do
7:    根据  $\varepsilon - greedy$  策略采样动作  $a_t$ 
8:    环境根据  $a_t$  反馈奖励  $r_t$  和下一个状态  $s_{t+1}$ 
9:    存储 transition 即  $(s_t, a_t, r_t, s_{t+1})$  到经验回放  $D$  中
10:   更新环境状态  $s_{t+1} \leftarrow s_t$ 
11:   更新策略:
12:   从  $D$  中采样一个 batch 的 transition
13:   计算实际的  $Q$  值, 即  $y_j$ ②
14:   对损失  $L(\theta) = (y_i - Q(s_i, a_i; \theta))^2$  关于参数  $\theta$  做随机梯度下降③
15:   end for
16:   每  $C$  个回合复制参数  $\hat{Q} \leftarrow Q$ ④
17: end for

```

---



---

<sup>①</sup>Playing Atari with Deep Reinforcement Learning

<sup>②</sup>
$$y_i = \begin{cases} r_i & \text{对于终止状态 } s_{i+1} \\ r_i + \gamma \max_{a'} Q(s_{i+1}, a'; \theta) & \text{对于非终止状态 } s_{i+1} \end{cases}$$

<sup>③</sup> $\theta_i \leftarrow \theta_i - \lambda \nabla_{\theta_i} L_i(\theta_i)$

<sup>④</sup>此处也可像原论文中放到小循环中改成每  $C$  步, 但没有每  $C$  个回合稳定

## 5 PERDQN 算法

---

### PER\_DQN 算法<sup>①</sup>

---

- 1: 初始化策略网络参数  $\theta$
  - 2: 复制参数到目标网络  $\hat{Q} \leftarrow Q$
  - 3: 初始化经验回放  $D$
  - 4: **for** 回合数 = 1,  $M$  **do**
  - 5:   重置环境, 获得初始状态  $s_t$
  - 6:   **for** 时步 = 1,  $t$  **do**
  - 7:     根据  $\varepsilon - greedy$  策略采样动作  $a_t$
  - 8:     环境根据  $a_t$  反馈奖励  $r_t$  和下一个状态  $s_{t+1}$
  - 9:     存储 transition 即  $(s_t, a_t, r_t, s_{t+1})$  到经验回放  $D$ , 并根据 TD-error 损失确定其优先级  $p_t$
  - 10:    更新环境状态  $s_{t+1} \leftarrow s_t$
  - 11:    **更新策略:**
  - 12:    按照经验回放中的优先级别, 每个样本采样概率为  $P(j) = p_j^\alpha / \sum_i p_i^\alpha$ , 从  $D$  中采样一个大小为 batch 的 transition
  - 13:    计算各个样本重要性采样权重  $w_j = (N \cdot P(j))^{-\beta} / \max_i w_i$
  - 14:    计算 TD-error  $\delta_j$ ; 并根据 TD-error 更新优先级  $p_j$
  - 15:    计算实际的  $Q$  值, 即  $y_j$ <sup>②</sup>
  - 16:    根据重要性采样权重调整损失  $L(\theta) = (y_j - Q(s_j, a_j; \theta) \cdot w_j)^2$ , 并将其关于参数  $\theta$  做随机梯度下降<sup>③</sup>
  - 17:    **end for**
  - 18:    每  $C$  个回合复制参数  $\hat{Q} \leftarrow Q$ <sup>④</sup>
  - 19: **end for**
- 

<sup>①</sup>Playing Atari with Deep Reinforcement Learning

<sup>②</sup>
$$y_i = \begin{cases} r_i & \text{对于终止状态 } s_{i+1} \\ r_i + \gamma \max_{a'} Q(s_{i+1}, a'; \theta) & \text{对于非终止状态 } s_{i+1} \end{cases}$$

<sup>③</sup> $\theta_i \leftarrow \theta_i - \lambda \nabla_{\theta_i} L_i(\theta_i)$

<sup>④</sup>此处也可像原论文中放到小循环中改成每  $C$  步, 但没有每  $C$  个回合稳定

## 6 Policy Gradient 算法

---

**REINFORCE 算法: Monte-Carlo Policy Gradient<sup>①</sup>**

---

```
1: 初始化策略参数  $\theta \in \mathbb{R}^{d'}$  ( e.g., to  $\mathbf{0}$  )
2: for 回合数 =  $1, M$  do
3:   根据策略  $\pi(\cdot | \cdot, \theta)$  采样一个 (或几个) 回合的 transition
4:   for 时步 =  $0, 1, 2, \dots, T-1$  do
5:     计算回报  $G \leftarrow \sum_{k=t+1}^T \gamma^{k-t-1} R_k$ 
6:     更新策略  $\theta \leftarrow \theta + \alpha \gamma^t G \nabla \ln \pi(A_t | S_t, \theta)$ 
7:   end for
8: end for
```

---

---

<sup>①</sup>Reinforcement Learning: An Introduction

## 7 Advantage Actor Critic 算法

---

### Q Actor Critic 算法

---

- 1: 初始化 Actor 参数  $\theta$  和 Critic 参数  $w$
  - 2: **for** 回合数 = 1,  $M$  **do**
  - 3:   根据策略  $\pi_\theta(a|s)$  采样一个 (或几个) 回合的 transition
  - 4:   **更新 Critic 参数**<sup>①</sup>
  - 5:   **for** 时步 =  $t + 1, 1$  **do**
  - 6:     计算 Advantage, 即  $\delta_t = r_t + \gamma Q_w(s_{t+1}, a_{t+1}) - Q_w(s_t, a_t)$
  - 7:      $w \leftarrow w + \alpha_w \delta_t \nabla_w Q_w(s_t, a_t)$
  - 8:      $a_t \leftarrow a_{t+1}, s_t \leftarrow s_{t+1}$
  - 9:   **end for**
  - 10:   更新 Actor 参数  $\theta \leftarrow \theta + \alpha_\theta Q_w(s, a) \nabla_\theta \log \pi_\theta(a | s)$
  - 11: **end for**
- 

---

<sup>①</sup>这里结合 TD error 的特性按照从  $t + 1$  到 1 计算法 Advantage 更方便



## 8 PPO-Clip 算法

---

### PPO-Clip 算法<sup>①②</sup>

---

```

1: 初始化策略网络 (Actor) 参数  $\theta$  和价值网络 (Critic) 参数  $\phi$ 
2: 初始化 Clip 参数  $\epsilon$ 
3: 初始化 epoch 数量  $K$ 
4: 初始化经验回放  $D$ 
5: 初始化总时步数  $c = 0$ 
6: for 回合数  $= 1, 2, \dots, M$  do
7:   重置环境, 获得初始状态  $s_0$ 
8:   for 时步  $t = 1, 2, \dots, T$  do
9:     计数总时步  $c \leftarrow c + 1$ 
10:    根据策略  $\pi_\theta$  选择  $a_t$ 
11:    环境根据  $a_t$  反馈奖励  $r_t$  和下一个状态  $s_{t+1}$ 
12:    存储  $(s_t, a_t, r_t, s_{t+1})$  到经验回放  $D$  中
13:    if  $c$  被  $C$  整除③ then
14:      for  $k = 1, 2, \dots, K$  do
15:        测试
16:      end for
17:      清空经验回放  $D$ 
18:    end if
19:  end for
20: end for

```

---



---

<sup>①</sup>Proximal Policy Optimization Algorithms

<sup>②</sup><https://spinningup.openai.com/en/latest/algorithms/ppo.html>

<sup>③</sup>即每  $C$  个时步更新策略

## 9 DDPG 算法

---

### DDPG 算法<sup>①</sup>

---

- 1: 初始化 critic 网络  $Q(s, a | \theta^Q)$  和 actor 网络  $\mu(s | \theta^\mu)$  的参数  $\theta^Q$  和  $\theta^\mu$
  - 2: 初始化对应的目标网络参数, 即  $\theta^{Q'} \leftarrow \theta^Q, \theta^{\mu'} \leftarrow \theta^\mu$
  - 3: 初始化经验回放  $R$
  - 4: **for** 回合数  $= 1, M$  **do**
  - 5:   选择动作  $a_t = \mu(s_t | \theta^\mu) + \mathcal{N}_t$ ,  $\mathcal{N}_t$  为探索噪声
  - 6:   环境根据  $a_t$  反馈奖励  $s_t$  和下一个状态  $s_{t+1}$
  - 7:   存储  $\text{transition}(s_t, a_t, r_t, s_{t+1})$  到经验回放  $R$  中
  - 8:   更新环境状态  $s_{t+1} \leftarrow s_t$
  - 9:   **更新策略:**
  - 10:   从  $R$  中取出一个随机批量的  $(s_i, a_i, r_i, s_{i+1})$
  - 11:   求得  $y_i = r_i + \gamma Q'(s_{i+1}, \mu'(s_{i+1} | \theta^{\mu'}) | \theta^{Q'})$
  - 12:   更新 critic 参数, 其损失为:  $L = \frac{1}{N} \sum_i (y_i - Q(s_i, a_i | \theta^Q))^2$
  - 13:   更新 actor 参数:  $\nabla_{\theta^\mu} J \approx \frac{1}{N} \sum_i \nabla_a Q(s, a | \theta^Q) \Big|_{s=s_i, a=\mu(s_i)} \nabla_{\theta^\mu} \mu(s | \theta^\mu) \Big|_{s_i}$
  - 14:   软更新目标网络:  $\theta^{Q'} \leftarrow \tau \theta^Q + (1 - \tau) \theta^{Q'}, \theta^{\mu'} \leftarrow \tau \theta^\mu + (1 - \tau) \theta^{\mu'}$
  - 15: **end for**
- 

---

<sup>①</sup>Continuous control with deep reinforcement learning

## 10 SoftQ 算法

---

### SoftQ 算法

---

- 1: 初始化参数  $\theta$  和  $\phi$
  - 2: 复制参数  $\bar{\theta} \leftarrow \theta, \bar{\phi} \leftarrow \phi$
  - 3: 初始化经验回放  $D$
  - 4: **for** 回合数 = 1,  $M$  **do**
  - 5:   **for** 时步 = 1,  $t$  **do**
  - 6:     根据  $\mathbf{a}_t \leftarrow f^\phi(\xi; \mathbf{s}_t)$  采样动作, 其中  $\xi \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
  - 7:     环境根据  $a_t$  反馈奖励  $s_t$  和下一个状态  $s_{t+1}$
  - 8:     存储 transition 即  $(s_t, a_t, r_t, s_{t+1})$  到经验回放  $D$  中
  - 9:     更新环境状态  $s_{t+1} \leftarrow s_t$
  - 10:    **更新 soft Q 函数参数:**
  - 11:    对于每个  $s_{t+1}^{(i)}$  采样  $\{\mathbf{a}^{(i,j)}\}_{j=0}^M \sim q_{\mathbf{a}'}$
  - 12:    计算 empirical soft values  $V_{\text{soft}}^\theta(\mathbf{s}_t)^{\textcircled{1}}$
  - 13:    计算 empirical gradient  $J_Q(\theta)^{\textcircled{2}}$
  - 14:    根据  $J_Q(\theta)$  使用 ADAM 更新参数  $\theta$
  - 15:    **更新策略:**
  - 16:    对于每个  $s_t^{(i)}$  采样  $\{\xi^{(i,j)}\}_{j=0}^M \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
  - 17:    计算  $\mathbf{a}_t^{(i,j)} = f^\phi(\xi^{(i,j)}, \mathbf{s}_t^{(i)})$
  - 18:    使用经验估计计算  $\Delta f^\phi(\cdot; \mathbf{s}_t)^{\textcircled{3}}$
  - 19:    计算经验估计  $\frac{\partial J_\pi(\phi; \mathbf{s}_t)}{\partial \phi} \propto \mathbb{E}_\xi \left[ \Delta f^\phi(\xi; \mathbf{s}_t) \frac{\partial f^\phi(\xi; \mathbf{s}_t)}{\partial \phi} \right]$ , 即  $\hat{\nabla}_\phi J_\pi$
  - 20:    根据  $\hat{\nabla}_\phi J_\pi$  使用 ADAM 更新参数  $\phi$
  - 21:
  - 22:   **end for**
  - 23:   每  $C$  个回合复制参数  $\bar{\theta} \leftarrow \theta, \bar{\phi} \leftarrow \phi$
  - 24: **end for**
- 

---

$\textcircled{1} V_{\text{soft}}^\theta(\mathbf{s}_t) = \alpha \log \mathbb{E}_{q_{\mathbf{a}'}} \left[ \frac{\exp(\frac{1}{\alpha} Q_{\text{soft}}^\theta(\mathbf{s}_t, \mathbf{a}'))}{q_{\mathbf{a}'}(\mathbf{a}')} \right]$

$\textcircled{2} J_Q(\theta) = \mathbb{E}_{\mathbf{s}_t \sim q_{\mathbf{s}_t}, \mathbf{a}_t \sim q_{\mathbf{a}_t}} \left[ \frac{1}{2} \left( \hat{Q}_{\text{soft}}^\theta(\mathbf{s}_t, \mathbf{a}_t) - Q_{\text{soft}}^\theta(\mathbf{s}_t, \mathbf{a}_t) \right)^2 \right]$

$\textcircled{3} \Delta f^\phi(\cdot; \mathbf{s}_t) = \mathbb{E}_{\mathbf{a}_t \sim \pi^\phi} \left[ \kappa \left( \mathbf{a}_t, f^\phi(\cdot; \mathbf{s}_t) \right) \nabla_{\mathbf{a}'} Q_{\text{soft}}^\theta(\mathbf{s}_t, \mathbf{a}') \Big|_{\mathbf{a}' = \mathbf{a}_t} \right. \\ \left. + \alpha \nabla_{\mathbf{a}'} \kappa \left( \mathbf{a}', f^\phi(\cdot; \mathbf{s}_t) \right) \Big|_{\mathbf{a}' = \mathbf{a}_t} \right]$

## 11 SAC-S 算法

---

### SAC-S 算法<sup>①</sup>

---

```

1: 初始化参数  $\psi, \bar{\psi}, \theta, \phi$ 
2: for 回合数 = 1,  $M$  do
3:   for 时步 = 1,  $t$  do
4:     根据  $\mathbf{a}_t \sim \pi_\phi(\mathbf{a}_t | \mathbf{s}_t)$  采样动作  $a_t$ 
5:     环境反馈奖励和下一个状态,  $\mathbf{s}_{t+1} \sim p(\mathbf{s}_{t+1} | \mathbf{s}_t, \mathbf{a}_t)$ 
6:     存储 transition 到经验回放中,  $\mathcal{D} \leftarrow \mathcal{D} \cup \{(\mathbf{s}_t, \mathbf{a}_t, r(\mathbf{s}_t, \mathbf{a}_t), \mathbf{s}_{t+1})\}$ 
7:     更新环境状态  $\mathbf{s}_{t+1} \leftarrow \mathbf{s}_t$ 
8:     更新策略:
9:      $\psi \leftarrow \psi - \lambda_V \hat{\nabla}_\psi J_V(\psi)$ 
10:     $\theta_i \leftarrow \theta_i - \lambda_Q \hat{\nabla}_{\theta_i} J_Q(\theta_i)$  for  $i \in \{1, 2\}$ 
11:     $\phi \leftarrow \phi - \lambda_\pi \hat{\nabla}_\phi J_\pi(\phi)$ 
12:     $\bar{\psi} \leftarrow \tau\psi + (1 - \tau)\bar{\psi}$ 
13:   end for
14: end for

```

---



---

<sup>①</sup>Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor

## 12 SAC 算法

---

### SAC 算法<sup>①</sup>

---

- 1: 初始化网络参数  $\theta_1, \theta_2$  以及  $\phi$
  - 2: 复制参数到目标网络  $\bar{\theta}_1 \leftarrow \theta_1, \bar{\theta}_2 \leftarrow \theta_2$ ,
  - 3: 初始化经验回放  $D$
  - 4: **for** 回合数 = 1,  $M$  **do**
  - 5:   重置环境, 获得初始状态  $s_t$
  - 6:   **for** 时步 = 1,  $t$  **do**
  - 7:     根据  $\mathbf{a}_t \sim \pi_\phi(\mathbf{a}_t | \mathbf{s}_t)$  采样动作  $a_t$
  - 8:     环境反馈奖励和下一个状态,  $\mathbf{s}_{t+1} \sim p(\mathbf{s}_{t+1} | \mathbf{s}_t, \mathbf{a}_t)$
  - 9:     存储 transition 到经验回放中,  $\mathcal{D} \leftarrow \mathcal{D} \cup \{(\mathbf{s}_t, \mathbf{a}_t, r(\mathbf{s}_t, \mathbf{a}_t), \mathbf{s}_{t+1})\}$
  - 10:    更新环境状态  $s_{t+1} \leftarrow s_t$
  - 11:    **更新策略:**
  - 12:     更新  $Q$  函数,  $\theta_i \leftarrow \theta_i - \lambda_Q \hat{\nabla}_{\theta_i} J_Q(\theta_i)$  for  $i \in \{1, 2\}$ <sup>②③</sup>
  - 13:     更新策略权重,  $\phi \leftarrow \phi - \lambda_\pi \hat{\nabla}_\phi J_\pi(\phi)$ <sup>④</sup>
  - 14:     调整 temperature,  $\alpha \leftarrow \alpha - \lambda \hat{\nabla}_\alpha J(\alpha)$ <sup>⑤</sup>
  - 15:     更新目标网络权重,  $\bar{\theta}_i \leftarrow \tau \theta_i + (1 - \tau) \bar{\theta}_i$  for  $i \in \{1, 2\}$
  - 16:   **end for**
  - 17: **end for**
- 

---

<sup>①</sup>Soft Actor-Critic Algorithms and Applications

<sup>②</sup>  $J_Q(\theta) = \mathbb{E}_{(\mathbf{s}_t, \mathbf{a}_t) \sim \mathcal{D}} \left[ \frac{1}{2} (Q_\theta(\mathbf{s}_t, \mathbf{a}_t) - (r(\mathbf{s}_t, \mathbf{a}_t) + \gamma \mathbb{E}_{\mathbf{s}_{t+1} \sim p} [V_{\bar{\theta}}(\mathbf{s}_{t+1})]))^2 \right]$

<sup>③</sup>  $\hat{\nabla}_\theta J_Q(\theta) = \nabla_\theta Q_\theta(\mathbf{a}_t, \mathbf{s}_t) (Q_\theta(\mathbf{s}_t, \mathbf{a}_t) - (r(\mathbf{s}_t, \mathbf{a}_t) + \gamma (Q_{\bar{\theta}}(\mathbf{s}_{t+1}, \mathbf{a}_{t+1}) - \alpha \log(\pi_\phi(\mathbf{a}_{t+1} | \mathbf{s}_{t+1}))))$

<sup>④</sup>  $\hat{\nabla}_\phi J_\pi(\phi) = \nabla_\phi \alpha \log(\pi_\phi(\mathbf{a}_t | \mathbf{s}_t)) + (\nabla_{\mathbf{a}_t} \alpha \log(\pi_\phi(\mathbf{a}_t | \mathbf{s}_t)) - \nabla_{\mathbf{a}_t} Q(\mathbf{s}_t, \mathbf{a}_t)) \nabla_\phi f_\phi(\epsilon_t; \mathbf{s}_t), \mathbf{a}_t = f_\phi(\epsilon_t; \mathbf{s}_t)$

<sup>⑤</sup>  $J(\alpha) = \mathbb{E}_{\mathbf{a}_t \sim \pi_t} [-\alpha \log \pi_t(\mathbf{a}_t | \mathbf{s}_t) - \alpha \bar{\mathcal{H}}]$